

Analiza ekonometryczna czynników determinujących kurs Bitcoina w latach 2023–2026.

Michał Dyrka & Nikodem Kusiak

Contents

1	Opis tematu.	1
1.0.1	1. Zacztywanie bibliotek na których będziemy pracować.	2
1.0.2	2. Zacztywanie danych na których będziemy pracować. Oraz od razu je oczyścimy i przygotujemy do analizy:	2
1.0.3	3. Stworzenie data frame.	2
1.0.4	4. Usuwamy wiersze które nie posiadają danych.	2
2	Analiza posiadanych danych	3
2.0.1	1. Zapoznajmy się z oczyszczonymi danymi.	3
2.0.2	2. Analiza korelacji danych.	4
2.0.3	3. Badanie stacjonarności szeregów czasowych	5
2.0.4	4. Potwierdzenie testu ADF.	6
2.0.5	5. Modyfikacja danych.	6
2.0.6	6. Dzielimy dane na zbiór uczący (80%) i testowy (20%).	7
2.0.7	7. Ponowna weryfikacja korelacji zmiennych na zbiorze uczącym.	8
3	Budowa modelu	8
3.1	Weryfikacja poprawności modelu ekonometrycznego	9
3.1.1	1. Normalność rozkładu składnika losowego – test Jarque-Bera	9
3.1.2	2. Autokorelacja składnika losowego	9
3.1.3	3. Homoskedastyczność składnika losowego	10
3.1.4	4. Współliniowość	11
3.1.5	5. Stabilność parametrów – test Chowa	11
3.1.6	6. Postać analityczna i liniowość – test RESET (Ramseya) i test liczby serii	11
3.1.7	7. Koincydencja	12
3.1.8	8. Efekt katalizy	12
3.2	Uwiarygodnienie testów (HAC)	12
3.3	Ostateczna postać modelu i jego ocena	13
3.4	Prognoza na zbiorze testowym	13
4	Podsumowanie	14

1 Opis tematu.

Gwałtowny rozwój rynków cyfrowych w ostatniej dekadzie wywołał szeroką dyskusję na temat statusu ekonomicznego kryptowaluty Bitcoin (BTC). Z jednej strony, ze względu na ograniczoną podaż i zdecentralizowaną naturę, Bitcoin określa się jako „cyfrowe złoto” i jest traktowany jako bezpieczna przystań w okresach niepewności rynkowej. Jednak istnieje wysoka zmienność oraz napływ kapitału instytucjonalnego sprawiają, że wielu inwestorów klasyfikuje go jako spekulacyjne aktywo technologiczne o wysokim współczynniku beta.

Projekt ma na celu identyfikację oraz ilościową ocenę siły powiązań kursu Bitcoina z tradycyjnymi aktywami w latach 2023–2026. Okres ten charakteryzował się istotnymi zmianami w polityce monetarnej banków centralnych (w tym Rezerwy Federalnej USA), napływem kapitału na skutek zatwierdzenia spotowych funduszy ETF na Bitcoinie oraz strukturalnym procesem halvingu w 2024 roku.

Jako zmienne objaśniające do modelu ekonometrycznego wybrano trzy kluczowe indykatory makroekonomiczne:

- **S&P 500 (spx)** – wskaźnik, który ukazuje, jak radzi sobie 500 największych firm w USA,
- **Złoto (xau)** – reprezentujące rynek tradycyjnych surowców i bezpiecznych przystani,
- **USD Index (usd)** – odzwierciedlający siłę światowej waluty rezerwowej i globalną płynność.

Dla dalszej analizy przyjmujemy poziom istotności $\alpha = 0,05$ (5%).

1.0.1 1. Zaczycie bibliotek na których będziemy pracować.

```
library(dplyr)
library(readr)
library(lubridate)    # change to "Date" type
library(skimr)        # present stats about our data frame
library(tseries)      # Testy stacjonarności (ADF, KPSS)
library(lmtest)       # Testy dla modeli (np. Breuscha-Pagana, Durbina-Watsona, RESET)
library(car)          # Testowanie współliniowości (VIF)
library(sandwich)     # Odporne błędy standardowe
library(strucchange)  # Test Chowa
library(randtests)    # Test liczby serii
```

1.0.2 2. Zaczycie danych na których będziemy pracować. Oraz od razu je oczyścimy i przygotujemy do analizy:

- z racji, że **S&P 500** posiada dodatkową kolumnę, usuwamy ją ponieważ pozostałe zmienne jej nie zawierają,
- zmieniamy format kolumny **data** na *"Date"*, zamiast *"char"*,
- wybierzemy kolumnę **zamknięcia** która będzie *ceną reprezentatywną* w danym dniu.

```
btc <- read.csv("data/btcusd_d.csv") %>% mutate(Data = ymd(Data)) %>% select(Data, btc = Zamknięcie)
spx <- read.csv("data/spx_d.csv") %>% mutate(Data = ymd(Data)) %>% select(Data, spx = Zamknięcie)
usd <- read.csv("data/usd_i_d.csv") %>% mutate(Data = ymd(Data)) %>% select(Data, usd = Zamknięcie)
xau <- read.csv("data/xauusd_d.csv") %>% mutate(Data = ymd(Data)) %>% select(Data, xau = Zamknięcie)
```

1.0.3 3. Stworzenie data frame.

Aby móc jak najlepiej przeanalizować dane, musimy stworzyć jeden **data frame** który będzie przechowywał dla danej daty informację z ceną dla poszczególnych zmiennych.

```
df <- btc %>%
  left_join(usd, by = "Data") %>%
  left_join(spx, by = "Data") %>%
  left_join(xau, by = "Data")
```

1.0.4 4. Usuwamy wiersze które nie posiadają danych.

```
df <- na.omit(df) # usuwanie wierszy z brakiem danych
skim(df)
```

Table 1: Data summary

Name	df
Number of rows	752
Number of columns	5
Column type frequency:	
Date	1
numeric	4
Group variables	None

Variable type: Date

skim_variable	n_missing	complete_rate	min	max	median	n_unique
Data	0	1	2023-04-03	2026-04-01	2024-09-30	752

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
btc	0	1	69942.65	29420.00	25119.00	42742.72	67878.70	95398.60	125173.00	
usd	0	1	63.24	1.62	59.95	61.85	63.22	64.53	67.20	
spx	0	1	5542.02	869.34	4055.99	4756.03	5598.21	6226.00	6978.60	
xau	0	1	2840.62	910.19	1820.26	2028.61	2606.90	3344.81	5415.17	

Wnioski:

- Posiadamy 752 wiersze, czyli 750 stopni swobody, co zapewnia wiarygodne wyniki testów,
- zakres czasowy od kwietnia 2023, do kwietnia 2026,
- 4 kolumny numeryczne, 1 typu *Date*.

Pierwotne szeregi czasowe charakteryzują się różnymi dniami handlu na giełdzie – Bitcoin notowany jest w systemie ciągłym (24/7), a rynki tradycyjne (S&P 500, Złoto, USD Index) funkcjonują wyłącznie w dni robocze. W celu uniknięcia błędów oraz eliminacji braków danych wynikających z przerw weekendowych i świątecznych na rynkach tradycyjnych, z szeregu czasowego Bitcoina usunięto weekendy oraz dni wolne od pracy giełdy amerykańskiej. **Ostatecznie próba badawcza liczy 752 obserwacje, co stanowi optymalną i statystycznie dużą próbę dla Klasycznej Metody Najmniejszych Kwadratów.**

2 Analiza posiadanych danych


2.0.1 1. Zapoznajmy się z oczyszczonymi danymi.

```
summary(df)
```

```
##      Data      btc      usd      spx
## Min.   :2023-04-03 Min.   : 25119 Min.   :59.95 Min.   :4056
## 1st Qu.:2024-01-01 1st Qu.: 42743 1st Qu.:61.85 1st Qu.:4756
## Median :2024-09-30 Median : 67879 Median :63.22 Median :5598
## Mean   :2024-09-30 Mean   : 69943 Mean   :63.24 Mean   :5542
## 3rd Qu.:2025-07-02 3rd Qu.: 95399 3rd Qu.:64.53 3rd Qu.:6226
```

```
## Max. :2026-04-01 Max. :125173 Max. :67.20 Max. :6979
## xau
## Min. :1820
## 1st Qu.:2029
## Median :2607
## Mean :2841
## 3rd Qu.:3345
## Max. :5415
```

```
plot(df$Data, df$btc, type="l", col="blue", main="Cena BTC", xlab="Data", ylab="Cena")
```



Wnioski:

- cena Bitcoina wskazuje w 2024 roku *tendencję wzrostową*, szczególnie w I kwartale oraz IV kwartale 2024 roku,
- w roku 2026 na rynku Bitcoina doszło do *głębokiej korekty spadkowej*, w wyniku której cena aktywa uległa spadku o około 50% w stosunku do szczytu wartości

2.0.2 2. Analiza korelacji danych.

```
cor_matrix <- cor(df[, c("btc", "usd", "spx", "xau")])
cor_matrix
```

```
##          btc          usd          spx          xau
## btc  1.0000000 -0.2809151  0.8508109  0.6603372
## usd -0.2809151  1.0000000 -0.4073593 -0.5718519
## spx  0.8508109 -0.4073593  1.0000000  0.8958694
## xau  0.6603372 -0.5718519  0.8958694  1.0000000
```

Wnioski:

- **BTC vs USD (-0.28)**: korelacja jest ujemna, korelacja jest słaba co oznaczam, że ta zmienna nie opisuje najlepiej ceny BTC,
- **BTC vs SPX (0.85)**: bardzo silna korelacja dodatnia, BTC zachowuje się obecnie jak aktywo wysokiego ryzyka, korelując się z indeksem 500 największych spółek w USA,
- **BTC vs XAU (0.66)**: korelacja jest umiarkowanie silna, BTC można nazywać jako cyfrowe złoto, ale wciąż mocniej koreluje z giełdą SPX,
- **SPX vs XAU (0.89)**: korelacja między dwiema zmiennymi objaśniającymi jest bardzo wysoka, podejrzenie **współliniowości**, które zbadamy w późniejszej analizie.

2.0.3 3. Badanie stacjonarności szeregów czasowych

Analiza finansowych szeregów czasowych na podstawie surowych cen niesie za sobą wysokie ryzyko wystąpienia regresji pozornej tzn. sztucznie zawyżony współczynnik determinacji R^2 oraz istotności parametrów w sytuacji, gdy zmienne dzielą wspólny trend deterministyczny lub stochastyczny (tzn. dwie zupełnie niezależne od siebie rzeczy rosną lub spadają w tym samym czasie tylko dlatego, że podlegają np. wpływowi czasu, inflacji lub rozwojowi technologii). W celu wyeliminowania tego problemu, konieczne jest zbadanie i eliminacja niestacjonarności. W tym celu zastosowano testy pierwiastka jednostkowego o przeciwnych hipotezach:

Zgodnie z teorią MNK, badamy **stacjonarność**, aby uniknąć problemu regresji pozornej. Wykorzystujemy Test ADF (Augmented Dickey-Fuller test).

- **H0**: szereg czasowy nie jest stacjonarny
- **H1**: szereg czasowy jest stacjonarny

```
adf.test(df$btc)
```

```
##
## Augmented Dickey-Fuller Test
##
## data: df$btc
## Dickey-Fuller = -0.81161, Lag order = 9, p-value = 0.9606
## alternative hypothesis: stationary
```

```
adf.test(df$usd)
```

```
##
## Augmented Dickey-Fuller Test
##
## data: df$usd
## Dickey-Fuller = -2.3821, Lag order = 9, p-value = 0.4166
## alternative hypothesis: stationary
```

```
adf.test(df$spx)
```

```
##
## Augmented Dickey-Fuller Test
##
## data: df$spx
## Dickey-Fuller = -2.2986, Lag order = 9, p-value = 0.4519
## alternative hypothesis: stationary
```

```
adf.test(df$xau)
```

```
##
## Augmented Dickey-Fuller Test
##
```

```
## data: df$xau
## Dickey-Fuller = -1.866, Lag order = 9, p-value = 0.635
## alternative hypothesis: stationary
```

Wnioski:

- p-value testu ADF dla wszystkich zmiennych wynosi > 0.05 , w związku z czym brak podstaw aby odrzucić H_0 , zmienne są niestacjonarne. Budowanie modelu na takich danych prowadziłoby do błędnych wniosków.

2.0.4 4. Potwierdzenie testu ADF.

Dla potwierdzenia skorzystajmy z testu KPSS (Kwiatkowskiego-Phillipsa-Schmidta-Shina) którego hipotezy są odwrócone.

- **H0**: szereg czasowy jest stacjonarny
- **H1**: szereg czasowy nie jest stacjonarny

```
kpss.test(df$btc)
```

```
##
## KPSS Test for Level Stationarity
##
## data: df$btc
## KPSS Level = 8.6967, Truncation lag parameter = 6, p-value = 0.01
```

```
kpss.test(df$usd)
```

```
##
## KPSS Test for Level Stationarity
##
## data: df$usd
## KPSS Level = 3.2048, Truncation lag parameter = 6, p-value = 0.01
```

```
kpss.test(df$spx)
```

```
##
## KPSS Test for Level Stationarity
##
## data: df$spx
## KPSS Level = 10.168, Truncation lag parameter = 6, p-value = 0.01
```

```
kpss.test(df$xau)
```

```
##
## KPSS Test for Level Stationarity
##
## data: df$xau
## KPSS Level = 9.5487, Truncation lag parameter = 6, p-value = 0.01
```

Wnioski:

- potwierdzenie, że ceny są niestacjonarne, p-value $< 0,05$, odrzucamy H_0 , w związku z czym musimy zmodyfikować nasze dane aby szereg był stacjonarny.

2.0.5 5. Modyfikacja danych.

Lepszym rozwiązaniem będzie **analiza stóp zwrotu**, które badają codzienne zmiany cen. Stopy zwrotu są stacjonarne, dzięki czemu możemy zbadać, jak mocno te rynki na siebie wpływają.

```

df_returns <- df %>%
  arrange(Data) %>%
  mutate(
    r_btc = c(NA, diff(log(btc))),
    r_usd = c(NA, diff(log(usd))),
    r_spx = c(NA, diff(log(spx))),
    r_xau = c(NA, diff(log(xau)))
  ) %>%
  na.omit() # ruszanie wierszy po użyciu diff() - wyliczenie różnic (przyrostów)

adf.test(df_returns$r_btc)

##
## Augmented Dickey-Fuller Test
##
## data: df_returns$r_btc
## Dickey-Fuller = -8.0891, Lag order = 9, p-value = 0.01
## alternative hypothesis: stationary

adf.test(df_returns$r_usd)

##
## Augmented Dickey-Fuller Test
##
## data: df_returns$r_usd
## Dickey-Fuller = -8.7503, Lag order = 9, p-value = 0.01
## alternative hypothesis: stationary

adf.test(df_returns$r_spx)

##
## Augmented Dickey-Fuller Test
##
## data: df_returns$r_spx
## Dickey-Fuller = -8.7239, Lag order = 9, p-value = 0.01
## alternative hypothesis: stationary

adf.test(df_returns$r_xau)

##
## Augmented Dickey-Fuller Test
##
## data: df_returns$r_xau
## Dickey-Fuller = -9.4052, Lag order = 9, p-value = 0.01
## alternative hypothesis: stationary

```

Wnioski:

- dla wszystkich analizowanych zmiennych w postaci stóp zwrotu, test ADF pozwolił na odrzucenie hipotezy zerowej o niestacjonarności przy poziomie istotności $p < 0,01$. Szeregi są stacjonarne i umożliwiają dalszą estymację modelu.”

2.0.6 6. Dzielimy dane na zbiór uczący (80%) i testowy (20%).

```
n_obs <- nrow(df_returns)
breakdown <- round(n_obs * 0.8)

df_learn <- df_returns[1:breakdown, ]
df_test <- df_returns[(breakdown + 1):n_obs, ]
```

2.0.7 7. Ponowna weryfikacja korelacji zmiennych na zbiorze uczącym.

```
cor_learn <- cor(df_learn[, c("r_btc", "r_usd", "r_spx", "r_xau")])
cor_learn
```

```
##           r_btc      r_usd      r_spx      r_xau
## r_btc  1.00000000 -0.01770160  0.31868593  0.05135402
## r_usd -0.01770160  1.00000000 -0.02527268 -0.50034823
## r_spx  0.31868593 -0.02527268  1.00000000  0.06984523
## r_xau  0.05135402 -0.50034823  0.06984523  1.00000000
```

Wnioski:

- na podstawie obliczonych korelacji możemy zauważyć, że największa korelacja Bitcoina występuje z S&P 500, ponadto korelacja zmiennej objaśniającej z pozostałymi propozycjami nie posiada zbyt dużej korelacji.

3 Budowa modelu

Do wybrania ostatecznej postaci modelu zastosowano **metodę krokową wsteczną**. Polega ona na rozpoczęciu od modelu zawierającego wszystkie potencjalne zmienne objaśniające i sukcesywnym usuwaniu tych zmiennych, których eliminacja prowadzi do minimalizacji kryterium informacyjnego Akaike (AIC).

```
model_full <- lm(r_btc ~ r_usd + r_spx + r_xau, data = df_learn)
model_step <- step(model_full, direction = "backward")
```

```
## Start:  AIC=-4298.83
## r_btc ~ r_usd + r_spx + r_xau
##
##           Df Sum of Sq      RSS      AIC
## - r_usd    1  0.000017  0.46418 -4300.8
## - r_xau    1  0.000409  0.46457 -4300.3
## <none>                                0.46416 -4298.8
## - r_spx    1  0.051570  0.51573 -4237.5
##
## Step:  AIC=-4300.81
## r_btc ~ r_spx + r_xau
##
##           Df Sum of Sq      RSS      AIC
## - r_xau    1  0.000440  0.46462 -4302.2
## <none>                                0.46418 -4300.8
## - r_spx    1  0.051597  0.51578 -4239.5
##
## Step:  AIC=-4302.24
## r_btc ~ r_spx
##
##           Df Sum of Sq      RSS      AIC
## <none>                                0.46462 -4302.2
## - r_spx    1  0.052521  0.51714 -4239.9
```



```
summary(model_step)
```

```
##
## Call:
## lm(formula = r_btc ~ r_spx, data = df_learn)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.112523 -0.016076 -0.001816  0.014270  0.136826
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.001593   0.001139   1.398   0.163
## r_spx        0.969095   0.117770   8.229 1.18e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.02785 on 599 degrees of freedom
## Multiple R-squared:  0.1016, Adjusted R-squared:  0.1001
## F-statistic: 67.71 on 1 and 599 DF,  p-value: 1.184e-15
```

Algorytm krokowy zredukował model wyłącznie do jednej zmiennej objaśniającej – `r_spx`. Zmienne `r_usd` i `r_xau` zostały odrzucone, bo na stopach zwrotu praktycznie nie korelują z `r_btc` (odpowiednio -0.018 i 0.051). Co ciekawe, na stopach zwrotu znika też silna korelacja SPX i XAU widoczna na surowych wartościach (z 0.90 do 0.07) — była ona pozorna i wynikała ze wspólnego trendu w długim okresie. Parametr przy zmiennej `r_spx` okazał się wysoce istotny statystycznie (p-value 1.18e-15).

3.1 Weryfikacja poprawności modelu ekonometrycznego

Mając już oszacowany model trzeba sprawdzić czy są spełnione wszystkie założenia MNK.

3.1.1 1. Normalność rozkładu składnika losowego – test Jarque-Bera

Test Jarque-Bera bada normalność rozkładu reszt na podstawie ich **skośności** i **kurtozy**. Normalność reszt jest jednym z założeń MNK i warunkiem poprawności klasycznych testów istotności opartych na rozkładzie t-Studenta.

- **H0**: składnik losowy ma rozkład normalny
- **H1**: nie ma rozkładu normalnego

```
jarque.bera.test(residuals(model_step))
```

```
##
## Jarque Bera Test
##
## data: residuals(model_step)
## X-squared = 105.03, df = 2, p-value < 2.2e-16
```

Wnioski: P-value bardzo małe < 2.2e-16, czyli odrzucamy H0. Reszty nie mają rozkładu normalnego. Nie jest to duży problem, bo próba jest duża i estymator MNK pozostaje zgodny.

3.1.2 2. Autokorelacja składnika losowego

Autokorelacja oznacza, że składniki losowe w kolejnych okresach są ze sobą skorelowane, co narusza założenie MNK o niezależności reszt. Stosujemy dwa testy: **Durbina-Watsona** (wykrywa autokorelację I rzędu) oraz **Breuscha-Godfrey**a (uogólnienie wykrywające autokorelację wyższych rzędów).

- **H0**: brak autokorelacji
- **H1**: występuje autokorelacja

```
dwtest(model_step)
```

```
##
## Durbin-Watson test
##
## data: model_step
## DW = 2.0733, p-value = 0.8164
## alternative hypothesis: true autocorrelation is greater than 0
```

```
bgtest(model_step)
```

```
##
## Breusch-Godfrey test for serial correlation of order up to 1
##
## data: model_step
## LM test = 0.83576, df = 1, p-value = 0.3606
```

Wnioski: P-value 0.8164 i 0.3606, nie ma podstaw do odrzucenia H0. Autokorelacji w resztach nie ma, więc jedno z głównych założeń MNK jest spełnione - macierz wariancji-kowariancji składników losowych jest diagonalna.

3.1.3 3. Homoskedastyczność składnika losowego

Homoskedastyczność oznacza, że wariancja składnika losowego jest stała dla wszystkich obserwacji. Jej brak (heteroskedastyczność) nie psuje zgodności estymatora MNK, ale powoduje obciążenie błędów standardowych. **Test Breuscha-Pagana** opiera się na regresji pomocniczej kwadratów reszt na zmiennych objaśniających, natomiast **test Goldfelda-Quandt** dzieli próbę na dwie części i porównuje wariancje reszt w obu segmentach, wykrywa heteroskedastyczność monotoniczną.

- **H0**: wariancja składnika losowego jest stała (homoskedastyczność)
- **H1**: heteroskedastyczność

```
bptest(model_step)
```

```
##
## studentized Breusch-Pagan test
##
## data: model_step
## BP = 5.7757, df = 1, p-value = 0.01625
```

```
gqtest(model_step)
```

```
##
## Goldfeld-Quandt test
##
## data: model_step
## GQ = 0.876, df1 = 299, df2 = 298, p-value = 0.8734
## alternative hypothesis: variance increases from segment 1 to 2
```

Wnioski: Wyniki testów są sprzeczne - BP zwrócił p-value 0.01625 (odrzucaamy H0), a GQ p-value 0.8734 (H0 zostaje). BP wychwytuje ogólniejszą zależność wariancji od zmiennej objaśniającej, GQ tylko monotoniczną. Dla bezpieczeństwa zastosujemy później odporne błędy standardowe HAC.

3.1.4 4. Współliniowość

Współczynnik **VIF** mierzy, o ile zwiększa się wariancja oszacowania parametru z powodu współliniowości między zmiennymi objaśniającymi. Przyjmuje się, że wartości $VIF > 5$ sygnalizują problem ze współliniowością.

```
if (length(coef(model_step)) > 2) {  
  vif(model_step)  
} else {  
  message("W modelu została tylko 1 zmienna objaśniająca, więc VIF nie ma sensu.")  
}
```

```
## W modelu została tylko 1 zmienna objaśniająca, więc VIF nie ma sensu.
```

Wnioski: Po eliminacji krokowej w modelu została jedna zmienna, więc nie ma jak obliczyć współczynnika VIF (potrzeba minimum dwóch zmiennych objaśniających).

3.1.5 5. Stabilność parametrów – test Chowa

Test Chowa służy do sprawdzenia, czy parametry modelu są takie same w dwóch wyznaczonych podpróbach (stabilność struktury modelu w czasie). Odrzucenie H_0 oznaczałoby wystąpienie zmiany strukturalnej.

- **H0:** parametry modelu są stabilne w czasie
- **H1:** parametry nie są stabilne

```
sctest(formula(model_step), type = "Chow", point = floor(nrow(df_learn)/2), data = df_learn)
```

```
##  
## Chow test  
##  
## data: formula(model_step)  
## F = 0.95961, p-value = 0.3836
```

Wnioski: P-value 0.3836, znowu H_0 nie odrzucamy. Parametry są stabilne między pierwszą a drugą połową próby uczącej.

3.1.6 6. Postać analityczna i liniowość – test RESET (Ramseya) i test liczby serii

Test RESET (Ramseya) sprawdza, czy do modelu nie należałoby dodać wyższych potęg wartości dopasowanych — jego odrzucenie sugeruje, że liniowa postać modelu jest niewystarczająca. **Test liczby serii** bada losowość znaków reszt — zbyt mała lub zbyt duża liczba serii świadczy o nielosowości i błędnej specyfikacji modelu.

- **H0:** postać modelu jest dobrze dobrana, model jest liniowy
- **H1:** model nie jest liniowy

```
resettest(model_step)
```

```
##  
## RESET test  
##  
## data: model_step  
## RESET = 2.6089, df1 = 2, df2 = 597, p-value = 0.07445
```

```
runs.test(residuals(model_step))
```

```
##  
## Runs Test  
##  
## data: residuals(model_step)
```

```
## statistic = 0.98061, runs = 313, n1 = 300, n2 = 300, n = 600, p-value =
## 0.3268
## alternative hypothesis: nonrandomness
```

Wnioski: RESET podał wynik p-value 0.07445, test liczby serii 0.3268 - w obu nie odrzucamy H_0 , liniowa postać modelu jest poprawna.

3.1.7 7. Koincydencja

Koincydencja oznacza zgodność znaku oszacowanego parametru ze znakiem korelacji prostej między zmienną objaśnianą a daną zmienną objaśniającą. Brak koincydencji może wskazywać na problemy ze specyfikacją modelu lub na występowanie efektu katalizy.

```
cor(df_learn$r_btc, df_learn$r_spx)
```

```
## [1] 0.3186859
```

```
coef(model_step)
```

```
## (Intercept)      r_spx
## 0.001592552 0.969094687
```

Wnioski: Korelacja BTC i SPX dodatnia (0.319), parametr przy r_{spx} też dodatni (0.969). Znaki się zgadzają, koincydencja spełniona.

3.1.8 8. Efekt katalizy

Efekt katalizy występuje, gdy w modelu pojawia się para zmiennych objaśniających, dla których korelacja jednej ze zmiennych ze zmienną objaśnianą oraz ich wzajemna korelacja prowadzą do sztucznego zawyżenia współczynnika determinacji R^2 . Bada się go najczęściej poprzez analizę par korelacji w macierzy korelacji zmiennych objaśniających względem zmiennej objaśnianej.

Wnioski: Po eliminacji krokowej w modelu została tylko jedna zmienna objaśniająca (r_{spx}), więc efekt katalizy z definicji nie może wystąpić.

3.2 Uwiarygodnienie testów (HAC)

Odporne błędy standardowe **HAC** pozostają wiarygodne nawet w obecności heteroskedastyczności i autokorelacji składnika losowego. Stosuje się je do uwiarygodnienia testów istotności, gdy klasyczne założenia MNK są naruszone. **Test Walda** służy z kolei do weryfikacji łącznej istotności jednego lub większej liczby parametrów w modelu.

Wyniki testów heteroskedastyczności są sprzeczne, dla pewności sprawdziliśmy istotność zmiennej również przy użyciu odpornych błędów standardowych HAC.

- H_0 : = 0
- H_1 : 0

```
coeftest(model_step, vcov = vcovHAC(model_step))
```

```
##
## t test of coefficients:
##
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 0.0015926 0.0011477 1.3876 0.1658
## r_spx       0.9690947 0.1561791 6.2050 1.021e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
waldtest(model_step, vcov = vcovHAC(model_step))
```

```
## Wald test
##
## Model 1: r_btc ~ r_spx
## Model 2: r_btc ~ 1
##   Res.Df Df       F    Pr(>F)
## 1     599
## 2     600 -1 38.502 1.021e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

P-value rzędu 10^{-9} - parametr przy `r_spx` jest istotny nawet przy odpornych błędach. Wnioski się potwierdzają.

3.3 Ostateczna postać modelu i jego ocena

Współczynnik determinacji R^2 informuje, jaka część zmienności zmiennej objaśnianej została wyjaśniona przez model. Przyjmuje wartości z przedziału $[0, 1]$ — im bliżej 1, tym lepsze dopasowanie modelu do danych.

```
summary(model_step)$r.squared
```

```
## [1] 0.1015607
```

Model jest oszacowany na stopach zwrotu (logarytmiczne pierwsze różnice), więc jest to prosta regresja liniowa:

$$r_btc_i = \beta_0 + \beta_1 \cdot r_spx_i + \varepsilon_i$$

Interpretacja parametru przy `r_spx` (ok. 0.97): Jeśli stopa zwrotu SPX wzrośnie o 1 jednostkę (tj. o 1 p.p.), to stopa zwrotu BTC wzrośnie średnio o 0.97 jednostki, ceteris paribus. W praktyce: jak amerykańska giełda rośnie o 1%, to BTC rośnie średnio o ok. 0.97%.

$R^2 = 0.1016$, czyli model wyjaśnia ok. 10.2% zmienności stóp zwrotu BTC. Na pierwszy rzut oka to mało, ale na dziennych danych z rynku to całkiem dobrze - ruchy cen są w dużej części losowe i nawet zaawansowane modele rzadko schodzą wysoko.

3.4 Prognoza na zbiorze testowym

Do oceny jakości prognozy na zbiorze testowym wykorzystano trzy miary błędów ex post: **RMSE** (pierwiastek błędu średniokwadratowego — w tych samych jednostkach co zmienna), **MAE** (średni absolutny błąd — odporny na wartości odstające) oraz **MAPE** (względny błąd procentowy).

```
predykcje <- predict(model_step, newdata = df_test)
```

```
# RMSE - pierwiastek błędu średniokwadratowego
rmse <- sqrt(mean((df_test$r_btc - predykcje)^2))
cat("RMSE:", rmse, "\n")
```

```
## RMSE: 0.02640299
```

```
# MAE - średni absolutny błąd
mae <- mean(abs(df_test$r_btc - predykcje))
cat("MAE:", mae, "\n")
```

```
## MAE: 0.02007188
```

```
# MAPE - średni absolutny błąd procentowy
mape <- mean(abs((df_test$r_btc - predykcje) / df_test$r_btc), na.rm = TRUE) * 100
cat("MAPE (względny błąd ex post):", round(mape, 2), "%\n")
```

```
## MAPE (względny błąd ex post): 123.9 %
```

Na zbiorze testowym RMSE wyszło ok. 0.026, czyli średnio mylimy się o ok. 2.6 p.p. stopy zwrotu. MAPE wyszło 123.9%, ale tę miarę trzeba brać z dystansem - stopy zwrotu często krążą wokół zera, a kiedy dzielimy przez liczby bliskie zera to MAPE drastycznie wzrasta. Dlatego sensowniejsze są tu RMSE i MAE.

4 Podsumowanie

Podsumowując, nawet tak prosty model regresji liniowej z jedną zmienną pokazał istotny, dodatni związek między indeksem SPX a kursem BTC. W badanym okresie Bitcoin zachowywał się raczej jak aktyw o wysokim ryzyku skorelowane z giełdą amerykańską niż jak “cyfrowe złoto”. Co ciekawe, zarówno złoto, jak i USD Index okazały się statystycznie nieistotne — silne korelacje widoczne na surowych cenach były pozorne i wynikały wyłącznie ze wspólnego trendu w długim okresie. Model spełnia większość założeń MNK, a jego istotność została dodatkowo potwierdzona przy użyciu odpornych błędów standardowych HAC. Niski współczynnik R^2 na poziomie ok. 10% jest typowy dla dziennych stóp zwrotu z rynków finansowych, gdzie duża część ruchów cen ma charakter losowy.