

Analiza ekonometryczna czynników determinujących kurs Bitcoina w latach 2023–2026.

Michał Dyrga & Nikodem Kusiak

Contents

1	Opis tematu.	2
1.0.1	1. Zacztywanie bibliotek na których będziemy pracować.	2
1.0.2	2. Zacztywanie danych na których będziemy pracować. Oraz od razu je oczyścimy i przygotujemy do analizy:	2
1.0.3	3. Stworzenie data frame.	2
1.0.4	4. Usuwamy wiersze które nie posiadają danych.	3
2	Analiza posiadanych danych	4
2.0.1	1. Zapoznajmy się z oczyszczonymi danymi.	4
2.0.2	2. Analiza korelacji danych.	5
2.0.3	3. Badanie stacjonarności szeregów czasowych	5
2.0.4	4. Potwierdzenie testu ADF.	6
2.0.5	5. Modyfikacja danych.	7
2.0.6	6. Dzielimy dane na zbiór uczący (80%) i testowy (20%).	8
2.0.7	7. Ponowna weryfikacja korelacji zmiennych na zbiorze uczącym.	8
3	Budowa modelu	9
3.1	Weryfikacja poprawności modelu ekonometrycznego	10
3.1.1	1. Normalność rozkładu składnika losowego – test Jarque-Bera	10
3.1.2	2. Autokorelacja składnika losowego	10
3.1.3	3. Homoskedastyczność składnika losowego	11
3.1.4	4. Współliniowość	11
3.1.5	5. Stabilność parametrów – test Chowa	12
3.1.6	6. Postać analityczna i liniowość – test RESET (Ramseya) i test liczby serii	12
3.1.7	7. Koincydencja	13
3.2	Uwiarygodnienie testów (HAC)	13
3.3	Ostateczna postać modelu i jego ocena	14
3.4	Prognoza na zbiorze testowym	14

1 Opis tematu.

Gwałtowny rozwój rynków cyfrowych w ostatniej dekadzie wywołał szeroką dyskusję na temat statusu ekonomicznego kryptowaluty Bitcoin (BTC). Z jednej strony, ze względu na ograniczoną podaż i zdecentralizowaną naturę, Bitcoin określa się jako „cyfrowe złoto” i jest traktowany jako bezpieczna przystań w okresach niepewności rynkowej. Jednak istnieje wysoka zmienność oraz napływ kapitału instytucjonalnego sprawiają, że wielu inwestorów klasyfikuje go jako spekulacyjne aktywo technologiczne o wysokim współczynniku beta.

Projekt ma na celu identyfikację oraz ilościową ocenę siły powiązań kursu Bitcoina z tradycyjnymi aktywami w latach 2023–2026. Okres ten charakteryzował się istotnymi zmianami w polityce monetarnej banków centralnych (w tym Rezerwy Federalnej USA), napływem kapitału na skutek zatwierdzenia spotowych funduszy ETF na Bitcoinie oraz strukturalnym procesem halvingu w 2024 roku.

Jako zmienne objaśniające do modelu ekonometrycznego wybrano trzy kluczowe indykatory makroekonomiczne:

- **S&P 500 (spx)** – wskaźnik, który ukazuje, jak radzi sobie 500 największych firm w USA,
- **Złoto (xau)** – reprezentujące rynek tradycyjnych surowców i bezpiecznych przystani,
- **USD Index (usd)** – odzwierciedlający siłę światowej waluty rezerwowej i globalną płynność.

1.0.1 1. Zaczytanie bibliotek na których będziemy pracować.

```
library(dplyr)
library(readr)
library(lubridate)    # change to "Date" type
library(skimr)        # present stats about our data frame
library(tseries)      # Testy stacjonarności (ADF, KPSS)
library(lmtest)       # Testy dla modeli (np. Breuscha-Pagana, Durбина-Watsona, RESET)
library(car)          # Testowanie współliniowości (VIF)
library(sandwich)      # Odporne błędy standardowe
library(strucchange)  # Test Chowa
library(randtests)    # Test liczby serii
```

1.0.2 2. Zaczytanie danych na których będziemy pracować. Oraz od razu je oczyścimy i przygotujemy do analizy:

- z racji, że **S&P 500** posiada dodatkową kolumnę, usuwamy ją ponieważ pozostałe zmienne jej nie zawierają,
- zmieniamy format kolumny **data** na “Date”, zamiast “char”,
- wybierzemy kolumnę **zamknięcia** która będzie ceną reprezentatywną w danym dniu.

```
btc <- read.csv("data/btcusd_d.csv") %>% mutate(Data = ymd(Data)) %>% select(Data, btc = Zamknięcie)
spx <- read.csv("data/spx_d.csv") %>% mutate(Data = ymd(Data)) %>% select(Data, spx = Zamknięcie)
usd <- read.csv("data/usd_i_d.csv") %>% mutate(Data = ymd(Data)) %>% select(Data, usd = Zamknięcie)
xau <- read.csv("data/xauusd_d.csv") %>% mutate(Data = ymd(Data)) %>% select(Data, xau = Zamknięcie)
```

1.0.3 3. Stworzenie data frame.

Aby móc jak najlepiej przeanalizować dane, musimy stworzyć jeden **data frame** który będzie przechowywał dla danej daty informację z ceną dla poszczególnych zmiennych.

```
df <- btc %>%
  left_join(usd, by = "Data") %>%
  left_join(spx, by = "Data") %>%
  left_join(xau, by = "Data")
```

1.0.4 4. Usuwanie wiersze które nie posiadają danych.

```
df <- na.omit(df) # usuniecie wierszy z brakiem danych
skim(df)
```

Table 1: Data summary

Name	df
Number of rows	752
Number of columns	5
Column type frequency:	
Date	1
numeric	4
Group variables	None

Variable type: Date

skim_variable	n_missing	complete_rate	min	max	median	n_unique
Data	0	1	2023-04-03	2026-04-01	2024-09-30	752

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
btc	0	1	69942.65	29420.00	25119.00	42742.72	67878.70	95398.60	125173.00	
usd	0	1	63.24	1.62	59.95	61.85	63.22	64.53	67.20	
spx	0	1	5542.02	869.34	4055.99	4756.03	5598.21	6226.00	6978.60	
xau	0	1	2840.62	910.19	1820.26	2028.61	2606.90	3344.81	5415.17	

Wnioski:

- Posiadamy 752 wiersze, czyli 750 stopni swobody, co zapewnia wiarygodne wyniki testów,
- zakres czasowy od kwietnia 2023, do kwietnia 2026,
- 4 kolumny numeryczne, 1 typu *Date*.

Pierwotne szeregi czasowe charakteryzują się różnymi dniami handlu na giełdzie – Bitcoin notowany jest w systemie ciągłym (24/7), a rynki tradycyjne (S&P 500, Złoto, USD Index) funkcjonują wyłącznie w dni robocze. W celu uniknięcia błędów oraz eliminacji braków danych wynikających z przerw weekendowych i świątecznych na rynkach tradycyjnych, z szeregu czasowego Bitcoina usunięto weekendy oraz dni wolne od pracy giełdy amerykańskiej. **Ostatecznie próba badawcza liczy 752 obserwacje, co stanowi optymalną i statystycznie dużą próbę dla Klasycznej Metody Najmniejszych Kwadratów.**


2 Analiza posiadanych danych

2.0.1 1. Zapoznajmy się z oczyszczonymi danymi.

```
summary(df)
```

```
##      Data          btc          usd          spx
## Min.   :2023-04-03   Min.    : 25119   Min.    :59.95   Min.    :4056
## 1st Qu.:2024-01-01   1st Qu.: 42743   1st Qu.:61.85   1st Qu.:4756
## Median :2024-09-30   Median : 67879   Median :63.22   Median :5598
## Mean   :2024-09-30   Mean    : 69943   Mean    :63.24   Mean    :5542
## 3rd Qu.:2025-07-02   3rd Qu.: 95399   3rd Qu.:64.53   3rd Qu.:6226
## Max.   :2026-04-01   Max.    :125173   Max.    :67.20   Max.    :6979
##
##      xau
## Min.   :1820
## 1st Qu.:2029
## Median :2607
## Mean   :2841
## 3rd Qu.:3345
## Max.   :5415
```

```
plot(df$Data, df$btc, type="l", col="blue", main="Cena BTC", xlab="Data", ylab="Cena")
```



Wnioski:

- cena Bitcoina wskazuje w 2024 roku *tendencję wzrostową*, szczególnie w I kwartale oraz IV kwartale 2024 roku,
- w roku 2026 na rynku Bitcoina doszło do *głębokiej korekty spadkowej*, w wyniku której cena aktywa uległa spadku o około 50% w stosunku do szczytu wartości

2.0.2 2. Analiza korelacji danych.

```
cor_matrix <- cor(df[, c("btc", "usd", "spx", "xau")])
cor_matrix
```

```
##          btc          usd          spx          xau
## btc  1.0000000 -0.2809151  0.8508109  0.6603372
## usd -0.2809151  1.0000000 -0.4073593 -0.5718519
## spx  0.8508109 -0.4073593  1.0000000  0.8958694
## xau  0.6603372 -0.5718519  0.8958694  1.0000000
```

Wnioski:

- **BTC vs USD (-0.28)**: korelacja jest ujemna, korelacja jest słaba co oznaczam, że ta zmienna nie opisuje najlepiej ceny BTC,
- **BTC vs SPX (0.85)**: bardzo silna korelacja dodatnia, BTC zachowuje się obecnie jak aktywo wysokiego ryzyka, korelując się z indeksem 500 największych spółek w USA,
- **BTC vs XAU (0.66)**: korelacja jest umiarkowanie silna, BTC można nazywać jako cyfrowe złoto, ale wciąż mocniej koreluje z giełdą SPX,
- **SPX vs XAU (0.89)**: korelacja między dwiema zmiennymi objaśniającymi jest bardzo wysoka, podejrzenie **współliniowości**, które zbadamy w późniejszej analizie.

2.0.3 3. Badanie stacjonarności szeregów czasowych

Analiza finansowych szeregów czasowych na podstawie surowych cen niesie za sobą wysokie ryzyko wystąpienia regresji pozornej tzn. sztucznie zawyżony współczynnik determinacji R^2 oraz istotności parametrów w sytuacji, gdy zmienne dzielą wspólny trend deterministyczny lub stochastyczny (tzn. dwie zupełnie niezależne od siebie rzeczy rosną lub spadają w tym samym czasie tylko dlatego, że podlegają np. wpływowi czasu, inflacji lub rozwojowi technologii). W celu wyeliminowania tego problemu, konieczne jest zbadanie i eliminacja niestacjonarności. W tym celu zastosowano testy pierwiastka jednostkowego o przeciwnych hipotezach:

Zgodnie z teorią MNK, badamy **stacjonarność**, aby uniknąć problemu regresji pozornej. Wykorzystujemy Test ADF (Augmented Dickey-Fuller test).

- **H0**: szereg czasowy nie jest stacjonarny
- **H1**: szereg czasowy jest stacjonarny

```
adf.test(df$btc)
```

```
##
## Augmented Dickey-Fuller Test
##
## data: df$btc
## Dickey-Fuller = -0.81161, Lag order = 9, p-value = 0.9606
## alternative hypothesis: stationary
```

```
adf.test(df$usd)
```

```
##  
## Augmented Dickey-Fuller Test  
##  
## data: df$usd  
## Dickey-Fuller = -2.3821, Lag order = 9, p-value = 0.4166  
## alternative hypothesis: stationary
```

```
adf.test(df$spx)
```

```
##  
## Augmented Dickey-Fuller Test  
##  
## data: df$spx  
## Dickey-Fuller = -2.2986, Lag order = 9, p-value = 0.4519  
## alternative hypothesis: stationary
```

```
adf.test(df$xau)
```

```
##  
## Augmented Dickey-Fuller Test  
##  
## data: df$xau  
## Dickey-Fuller = -1.866, Lag order = 9, p-value = 0.635  
## alternative hypothesis: stationary
```

Wnioski:

- p-value testu ADF dla wszystkich zmiennych wynosi ponad 0.05, w związku z czym brak podstaw aby odrzucić H_0 , zmienne są niestacjonarne. Budowanie modelu na takich danych prowadziłoby do błędnych wniosków.

2.0.4 4. Potwierdzenie testu ADF.

Dla potwierdzenia skorzystajmy z testu KPSS (Kwiatkowskiego-Phillipsa-Schmidta-Shina) którego hipotezy są odwrócone.

- **H_0** : szereg czasowy jest stacjonarny
- **H_1** : szereg czasowy nie jest stacjonarny

```
kpss.test(df$btc)
```

```
##  
## KPSS Test for Level Stationarity  
##  
## data: df$btc  
## KPSS Level = 8.6967, Truncation lag parameter = 6, p-value = 0.01
```

```
kpss.test(df$usd)
```

```
##  
## KPSS Test for Level Stationarity  
##  
## data: df$usd  
## KPSS Level = 3.2048, Truncation lag parameter = 6, p-value = 0.01
```

```
kpss.test(df$spx)
```

```
##  
## KPSS Test for Level Stationarity  
##  
## data: df$spx  
## KPSS Level = 10.168, Truncation lag parameter = 6, p-value = 0.01
```

```
kpss.test(df$xau)
```

```
##  
## KPSS Test for Level Stationarity  
##  
## data: df$xau  
## KPSS Level = 9.5487, Truncation lag parameter = 6, p-value = 0.01
```

Wnioski:

- potwierdzenie, że ceny są niestacjonarne, $p\text{-value} < 0,05$, odrzucamy H_0 , w związku z czym musimy zmodyfikować nasze dane aby szereg był stacjonarny.

2.0.5 5. Modyfikacja danych.

Lepszym rozwiązaniem będzie **analiza stóp zwrotu**, które badają codzienne zmiany cen. Stopy zwrotu są stacjonarne, dzięki czemu możemy zbadać, jak mocno te rynki na siebie wpływają.

```
df_returns <- df %>%  
  arrange(Data) %>%  
  mutate(  
    r_btc = c(NA, diff(log(btc))),  
    r_usd = c(NA, diff(log(usd))),  
    r_spx = c(NA, diff(log(spx))),  
    r_xau = c(NA, diff(log(xau)))  
  ) %>%  
  na.omit() # ruszanie wierszy po użyciu diff() - wyliczenie różnic (przyrostów)  
  
adf.test(df_returns$r_btc)
```

```
##  
## Augmented Dickey-Fuller Test  
##  
## data: df_returns$r_btc  
## Dickey-Fuller = -8.0891, Lag order = 9, p-value = 0.01  
## alternative hypothesis: stationary
```

```
adf.test(df_returns$r_usd)
```

```
##  
## Augmented Dickey-Fuller Test  
##  
## data: df_returns$r_usd  
## Dickey-Fuller = -8.7503, Lag order = 9, p-value = 0.01  
## alternative hypothesis: stationary
```

```
adf.test(df_returns$r_spx)
```

```
##  
## Augmented Dickey-Fuller Test  
##  
## data: df_returns$r_spx  
## Dickey-Fuller = -8.7239, Lag order = 9, p-value = 0.01  
## alternative hypothesis: stationary
```

```
adf.test(df_returns$r_xau)
```

```
##  
## Augmented Dickey-Fuller Test  
##  
## data: df_returns$r_xau  
## Dickey-Fuller = -9.4052, Lag order = 9, p-value = 0.01  
## alternative hypothesis: stationary
```

Wnioski:

- dla wszystkich analizowanych zmiennych w postaci stóp zwrotu, test ADF pozwolił na odrzucenie hipotezy zerowej o niestacjonarności przy poziomie istotności $p < 0,01$. Szeregi są stacjonarne i umożliwiają dalszą estymację modelu.”

2.0.6 6. Dzielimy dane na zbiór uczący (80%) i testowy (20%).

```
n_obs <- nrow(df_returns)  
breakdown <- round(n_obs * 0.8)  
  
df_learn <- df_returns[1:breakdown, ]  
df_test <- df_returns[(breakdown + 1):n_obs, ]
```

2.0.7 7. Ponowna weryfikacja korelacji zmiennych na zbiorze uczącym.

```
cor_learn <- cor(df_learn[, c("r_btc", "r_usd", "r_spx", "r_xau")])  
cor_learn
```



```
##           r_btc      r_usd      r_spx      r_xau
## r_btc  1.00000000 -0.01770160  0.31868593  0.05135402
## r_usd -0.01770160  1.00000000 -0.02527268 -0.50034823
## r_spx  0.31868593 -0.02527268  1.00000000  0.06984523
## r_xau  0.05135402 -0.50034823  0.06984523  1.00000000
```

Wnioski:

- na podstawie obliczonych korelacji możemy zauważyć, że największa korelacja Bitcoina występuje z S&P 500, ponadto korelacja zmiennej objaśniającej z pozostałymi propozycjami nie posiada zbyt dużej korelacji.

3 Budowa modelu

Zastosowano metodę krokową wsteczną do wybrania ostatecznej postaci modelu.

```
model_full <- lm(r_btc ~ r_usd + r_spx + r_xau, data = df_learn)
model_step <- step(model_full, direction = "backward")
```

```
## Start:  AIC=-4298.83
## r_btc ~ r_usd + r_spx + r_xau
##
##           Df Sum of Sq      RSS      AIC
## - r_usd   1  0.000017  0.46418 -4300.8
## - r_xau   1  0.000409  0.46457 -4300.3
## <none>                                0.46416 -4298.8
## - r_spx   1  0.051570  0.51573 -4237.5
##
## Step:  AIC=-4300.81
## r_btc ~ r_spx + r_xau
##
##           Df Sum of Sq      RSS      AIC
## - r_xau   1  0.000440  0.46462 -4302.2
## <none>                                0.46418 -4300.8
## - r_spx   1  0.051597  0.51578 -4239.5
##
## Step:  AIC=-4302.24
## r_btc ~ r_spx
##
##           Df Sum of Sq      RSS      AIC
## <none>                                0.46462 -4302.2
## - r_spx   1  0.052521  0.51714 -4239.9
```

```
summary(model_step)
```

```
##
## Call:
## lm(formula = r_btc ~ r_spx, data = df_learn)
##
## Residuals:
##           Min             1Q         Median             3Q            Max
```

```
## -0.112523 -0.016076 -0.001816 0.014270 0.136826
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 0.001593 0.001139 1.398 0.163
## r_spx       0.969095 0.117770 8.229 1.18e-15 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.02785 on 599 degrees of freedom
## Multiple R-squared: 0.1016, Adjusted R-squared: 0.1001
## F-statistic: 67.71 on 1 and 599 DF, p-value: 1.184e-15
```

Algorytm krokowy zredukował model wyłącznie do jednej zmiennej objaśniającej – `r_spx`. Zmienne `r_usd` i `r_xau` zostały odrzucone, bo na stopach zwrotu praktycznie nie korelują z `r_btc` (odpowiednio -0.018 i 0.051). Co ciekawe, na stopach zwrotu znika też silna korelacja SPX i XAU widoczna na surowych wartościach (z 0.90 do 0.07) — była ona pozorna i wynikała ze wspólnego trendu w długim okresie. Parametr przy zmiennej `r_spx` okazał się wysoce istotny statystycznie (p-value 1.18e-15).

3.1 Weryfikacja poprawności modelu ekonometrycznego

Mając już oszacowany model trzeba sprawdzić czy są spełnione wszystkie założenia MNK.

3.1.1 1. Normalność rozkładu składnika losowego – test Jarque-Bera

- **H0**: składnik losowy ma rozkład normalny
- **H1**: nie ma rozkładu normalnego

```
jarque.bera.test(residuals(model_step))
```

```
##
## Jarque Bera Test
##
## data: residuals(model_step)
## X-squared = 105.03, df = 2, p-value < 2.2e-16
```

Wnioski: P-value bardzo małe $< 2.2e-16$, czyli odrzucamy H_0 . Reszty nie mają rozkładu normalnego. Nie jest to duży problem, bo próba jest duża i estymator MNK pozostaje zgodny.

3.1.2 2. Autokorelacja składnika losowego

Stosujemy dwa testy: Durbina-Watsona (autokorelacja I rzędu) oraz Breuscha-Godfrey (wyższe rzędy). * **H0**: brak autokorelacji * **H1**: występuje autokorelacja

```
dwtest(model_step)
```

```
##
## Durbin-Watson test
##
```

```
## data: model_step
## DW = 2.0733, p-value = 0.8164
## alternative hypothesis: true autocorrelation is greater than 0
```

```
bgtest(model_step)
```

```
##
## Breusch-Godfrey test for serial correlation of order up to 1
##
## data: model_step
## LM test = 0.83576, df = 1, p-value = 0.3606
```

Wnioski: P-value 0.8164 i 0.3606, nie ma podstaw do odrzucenia H_0 . Autokorelacji w resztach nie ma, więc jedno z głównych założeń MNK jest spełnione - macierz wariancji-kowariancji składników losowych jest diagonalna.

3.1.3 3. Homoskedastyczność składnika losowego

Test Breuscha-Pagana oraz Goldfelda-Quandt. * **H0**: wariancja składnika losowego jest stała (homoskedastyczność) * **H1**: heteroskedastyczność

```
bpctest(model_step)
```

```
##
## studentized Breusch-Pagan test
##
## data: model_step
## BP = 5.7757, df = 1, p-value = 0.01625
```

```
gqtest(model_step)
```

```
##
## Goldfeld-Quandt test
##
## data: model_step
## GQ = 0.876, df1 = 299, df2 = 298, p-value = 0.8734
## alternative hypothesis: variance increases from segment 1 to 2
```

Wnioski: Wyniki testów są sprzeczne - BP zwrócił p-value 0.01625 (odrzucaamy H_0), a GQ p-value 0.8734 (H_0 zostaje). BP wychwytuje ogólniejszą zależność wariancji od zmiennej objaśniającej, GQ tylko monotoniczną. Dla bezpieczeństwa zastosujemy później odporne błędy standardowe HAC.

3.1.4 4. Współliniowość

Współczynnik VIF.

```
if (length(coef(model_step)) > 2) {
  vif(model_step)
} else {
  message("W modelu została tylko 1 zmienna objaśniająca, więc VIF nie ma sensu.")
}
```

W modelu została tylko 1 zmienna objaśniająca, więc VIF nie ma sensu.

Wnioski: Po eliminacji krokowej w modelu została jedna zmienna, więc nie ma jak obliczyć współczynnika VIF (potrzeba minimum dwóch zmiennych objaśniających).

3.1.5 5. Stabilność parametrów – test Chowa

- **H0:** parametry modelu są stabilne w czasie
- **H1:** parametry nie są stabilne

```
sctest(formula(model_step), type = "Chow", point = floor(nrow(df_learn)/2), data = df_learn)
```

```
##  
## Chow test  
##  
## data: formula(model_step)  
## F = 0.95961, p-value = 0.3836
```

Wnioski: P-value 0.3836, znowu H0 nie odrzucamy. Parametry są stabilne między pierwszą a drugą połową próby uczącej.

3.1.6 6. Postać analityczna i liniowość – test RESET (Ramseya) i test liczby serii

- **H0:** postać modelu jest dobrze dobrana, model jest liniowy
- **H1:** model nie jest liniowy

```
resettest(model_step)
```

```
##  
## RESET test  
##  
## data: model_step  
## RESET = 2.6089, df1 = 2, df2 = 597, p-value = 0.07445
```

```
runs.test(residuals(model_step))
```

```
##  
## Runs Test  
##  
## data: residuals(model_step)  
## statistic = 0.98061, runs = 313, n1 = 300, n2 = 300, n = 600, p-value =  
## 0.3268  
## alternative hypothesis: nonrandomness
```

Wnioski: RESET podał wynik p-value 0.07445, test liczby serii 0.3268 - w obu nie odrzucamy H0 (przy $\alpha = 0.05$), liniowa postać modelu jest poprawna.

3.1.7 7. Koïncydencja

Patrzmy czy znak korelacji BTC ze SPX z macierzy zgadza się ze znakiem oszacowanego parametru w modelu.

```
cor(df_learn$r_btc, df_learn$r_spx)
```

```
## [1] 0.3186859
```

```
coef(model_step)
```

```
## (Intercept)      r_spx  
## 0.001592552 0.969094687
```

Wnioski: Korelacja BTC i SPX dodatnia (0.319), parametr przy `r_spx` też dodatni (0.969).
Znaki się zgadzają, koïncydencja spełniona.

3.2 Uwiarygodnienie testów (HAC)

Wyniki testów heteroskedastyczności są sprzeczne, dla pewności sprawdziliśmy istotność zmiennej również przy użyciu odpornych błędów standardowych HAC.

```
coeftest(model_step, vcov = vcovHAC(model_step))
```

```
##  
## t test of coefficients:  
##  
##           Estimate Std. Error t value Pr(>|t|)  
## (Intercept) 0.0015926 0.0011477  1.3876   0.1658  
## r_spx       0.9690947 0.1561791  6.2050 1.021e-09 ***  
## ---  
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
waldtest(model_step, vcov = vcovHAC(model_step))
```

```
## Wald test  
##  
## Model 1: r_btc ~ r_spx  
## Model 2: r_btc ~ 1  
##   Res.Df Df    F    Pr(>F)  
## 1     599  
## 2     600 -1 38.502 1.021e-09 ***  
## ---  
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

P-value rzędu 10^{-9} - parametr przy `r_spx` jest istotny nawet przy odpornych błędach. Wnioski się potwierdzają.

3.3 Ostateczna postać modelu i jego ocena

Współczynnik determinacji R^2 :

```
summary(model_step)$r.squared
```

```
## [1] 0.1015607
```

Model jest oszacowany na stopach zwrotu (logarytmiczne pierwsze różnice), więc jest to prosta regresja liniowa:

$$r_{btc_i} = \beta_0 + \beta_1 \cdot r_{spx_i} + \varepsilon_i$$

Interpretacja parametru przy r_{spx} (ok. 0.97): Jeśli stopa zwrotu SPX wzrośnie o 1 jednostkę (tj. o 1 p.p.), to stopa zwrotu BTC wzrośnie średnio o 0.97 jednostki, ceteris paribus. W praktyce: jak amerykańska giełda rośnie o 1%, to BTC rośnie średnio o ok. 0.97%.

$R^2 = 0.1016$, czyli model wyjaśnia ok. 10.2% zmienności stóp zwrotu BTC. Na pierwszy rzut oka to mało, ale na dziennych danych z rynku to całkiem dobrze - ruchy cen są w dużej części losowe i nawet zaawansowane modele rzadko schodzą wysoko.

3.4 Prognoza na zbiorze testowym

```
predykcje <- predict(model_step, newdata = df_test)
```

```
# RMSE - pierwiastek błędu średniokwadratowego
rmse <- sqrt(mean((df_test$r_btc - predykcje)^2))
cat("RMSE:", rmse, "\n")
```

```
## RMSE: 0.02640299
```

```
# MAE - średni absolutny błąd
mae <- mean(abs(df_test$r_btc - predykcje))
cat("MAE:", mae, "\n")
```

```
## MAE: 0.02007188
```

```
# MAPE - średni absolutny błąd procentowy
mape <- mean(abs((df_test$r_btc - predykcje) / df_test$r_btc), na.rm = TRUE) * 100
cat("MAPE:", round(mape, 2), "%\n")
```

```
## MAPE: 123.9 %
```

Na zbiorze testowym RMSE wyszło ok. 0.026, czyli średnio mylimy się o ok. 2.6 p.p. stopy zwrotu. MAPE wyszło 123.9%, ale tę miarę trzeba brać z dystansem - stopy zwrotu często krążą wokół zera, a kiedy dzielimy przez liczby bliskie zera to MAPE drastycznie wzrasta. Dlatego sensowniejsze są tu RMSE i MAE.

Podsumowując, nawet tak prosty model regresji liniowej z jedną zmienną pokazał istotny, dodatni związek między indeksem SPX a kursem BTC. W badanym okresie Bitcoin zachowywał się raczej jak aktywo wysokiego ryzyka skorelowane z giełdą amerykańską niż jak “cyfrowe złoto”.